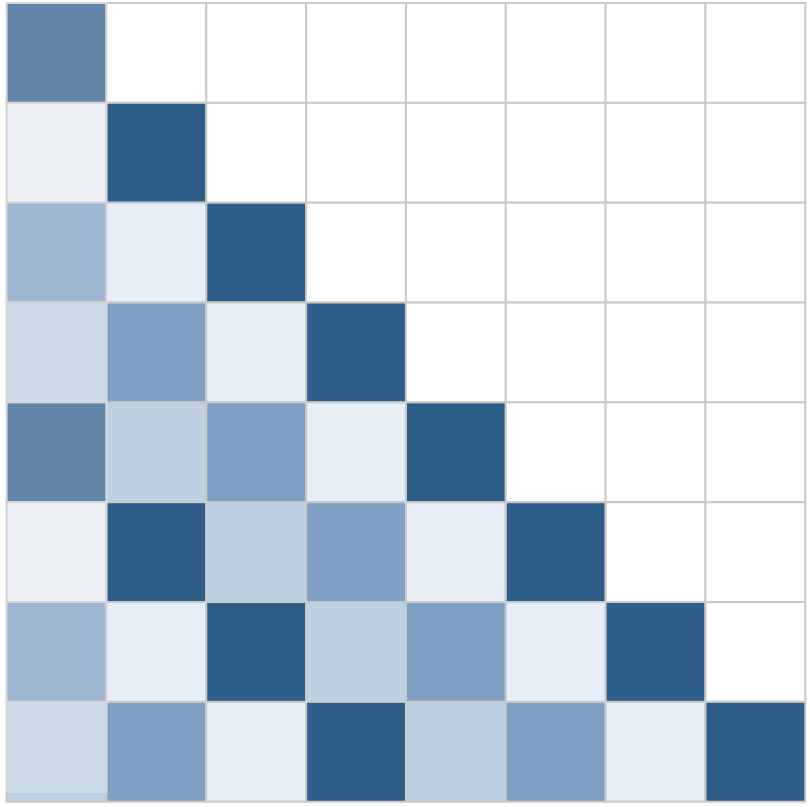
CESUPA TECH SUMMIT 2026 · WORKSHOP

Attention is All You Need

Construindo um Transformer do zero





Giovanni Vasconcelos

14 de outubro de 2026

ROTEIRO

O que vamos fazer hoje

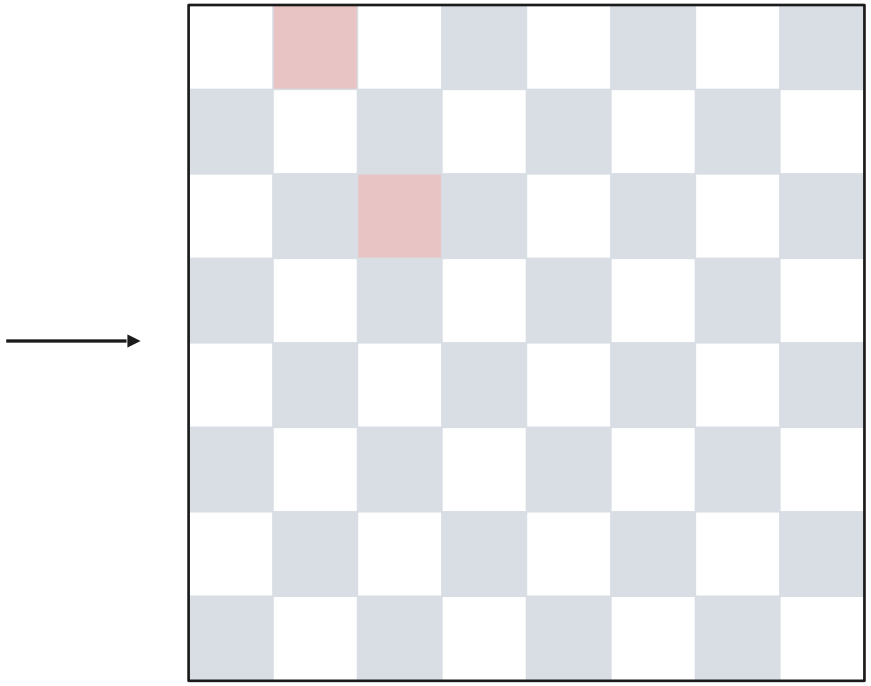
- ☐ De onde veio a ideia de atenção, e por que ela mudou a computação
- ■ Parte 1 **Fazer a atenção passo a passo, num exemplo de três palavras**
- ☐ Como a atenção vira um Transformer
- ■ Parte 2 **Montar o Transformer e ensiná-lo a ordenar números**
- ☐ Intervalo
- ■ Parte 3 **Treinar um modelo de xadrez e jogar contra ele**

Ninguém precisa saber nada de inteligência artificial, nem de xadrez.

Onde vamos chegar

```
;1.e4 e5 2.Nf3 Nc6 3.Bb5 a6
 4.Ba4 Nf6 5.O-O Be7 6.Re1 b5
 7.Bb3 d6 8.c3 O-O 9.h3 Nb8
```

O modelo lê apenas o texto e prevê o próximo caractere.



O tabuleiro nunca é mostrado ao modelo.

Um Transformer montado por vocês, que aprende xadrez só lendo partidas.

PREPARAÇÃO

Abrindo o notebook

1 **Abra o link**

`colab.research.google.com/github/giovannibragasv/transformer-do-zero/blob/main/workshop_aluno.ipynb`

2 **Salve uma cópia**

Arquivo > Salvar uma cópia no Drive

3 **Ative a GPU**

Ambiente de execução > Alterar o tipo de ambiente > T4 GPU

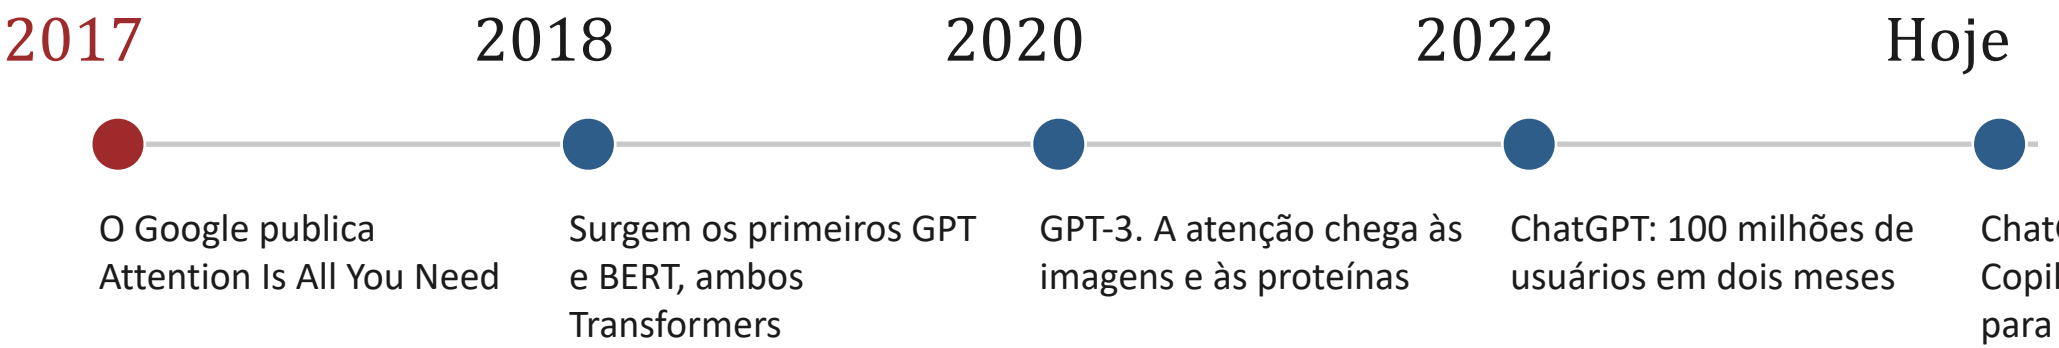
4 **Execute as células da seção 0**

Clique na célula e aperte Shift + Enter. A segunda deve imprimir: Dispositivo: cuda

Você só precisa de um navegador e de uma conta Google.

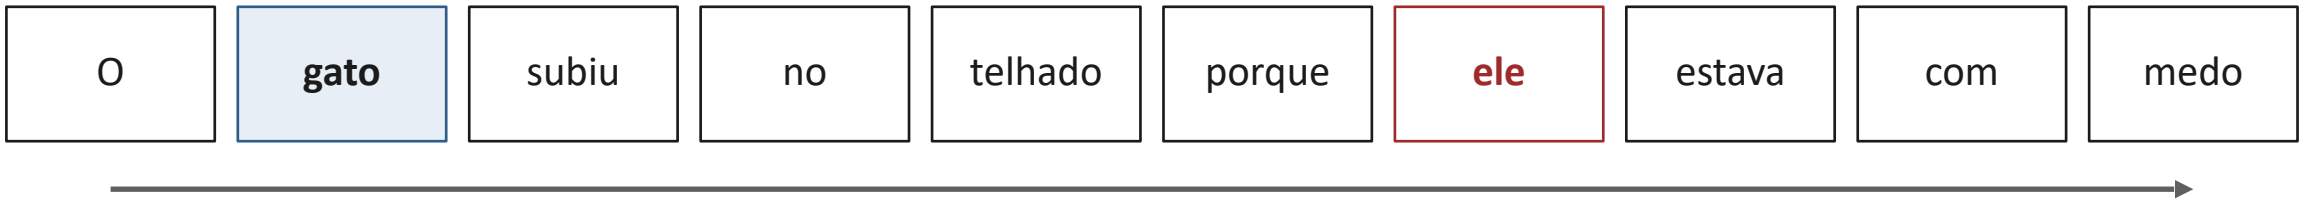
A HISTÓRIA

Uma ideia de 2017 que mudou a computação



O "T" de ChatGPT significa Transformer. É ele que vamos construir hoje.

Antes de 2017: ler uma palavra de cada vez



uma palavra por vez, passando um resumo adiante

Esquece

Quando chega em "ele", o "gato" já ficou lá atrás. É como um telefone sem fio: a mensagem se perde no caminho.

É lento

Cada palavra espera a anterior. Não dá para aproveitar a GPU, que faz milhares de contas ao mesmo tempo.

Um modelo de linguagem adivinha o que vem depois

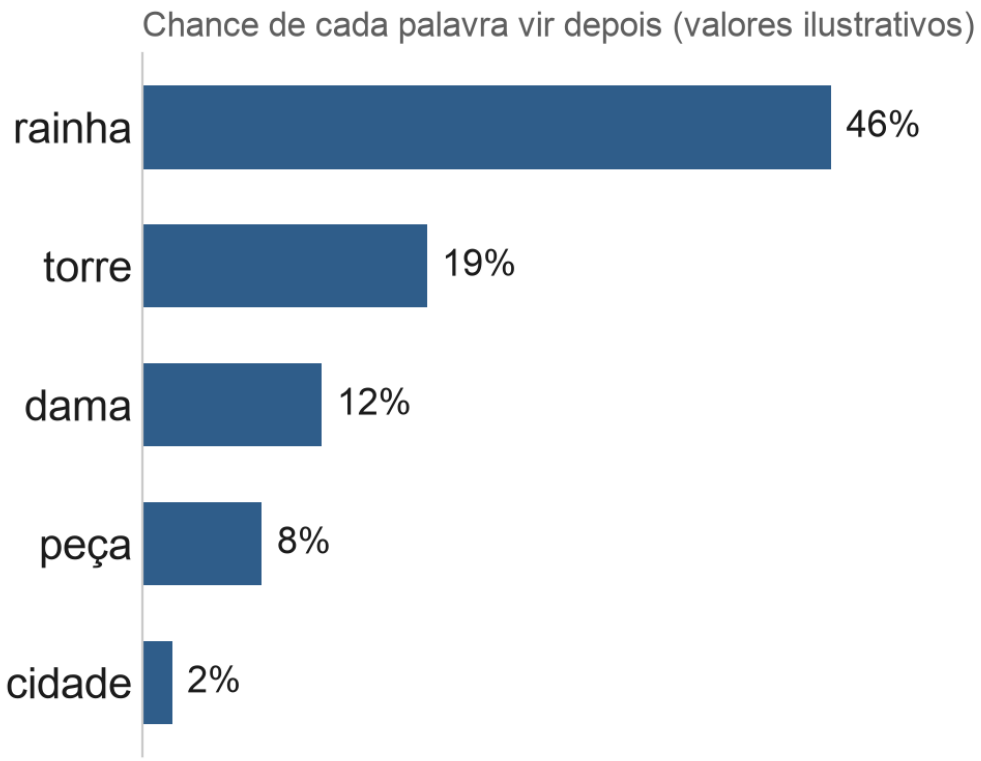
o rei protege a ___

Treinar

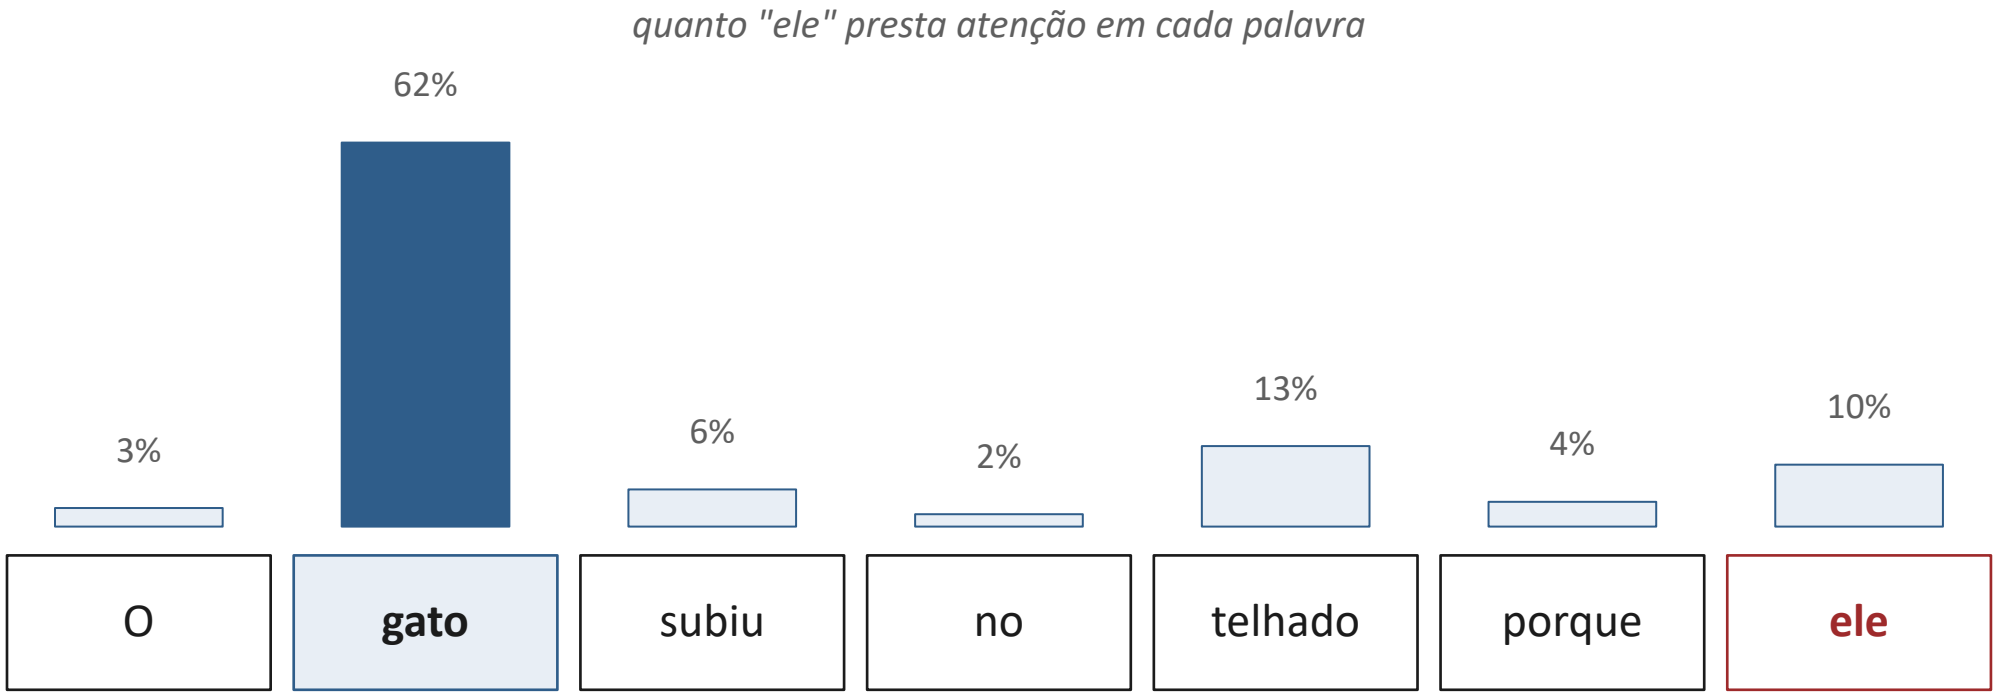
mostrar muito texto e ajustar o modelo até ele dar a maior chance à palavra certa.

Gerar

sortear uma palavra, acrescentar ao texto e prever de novo. É assim que o ChatGPT escreve.

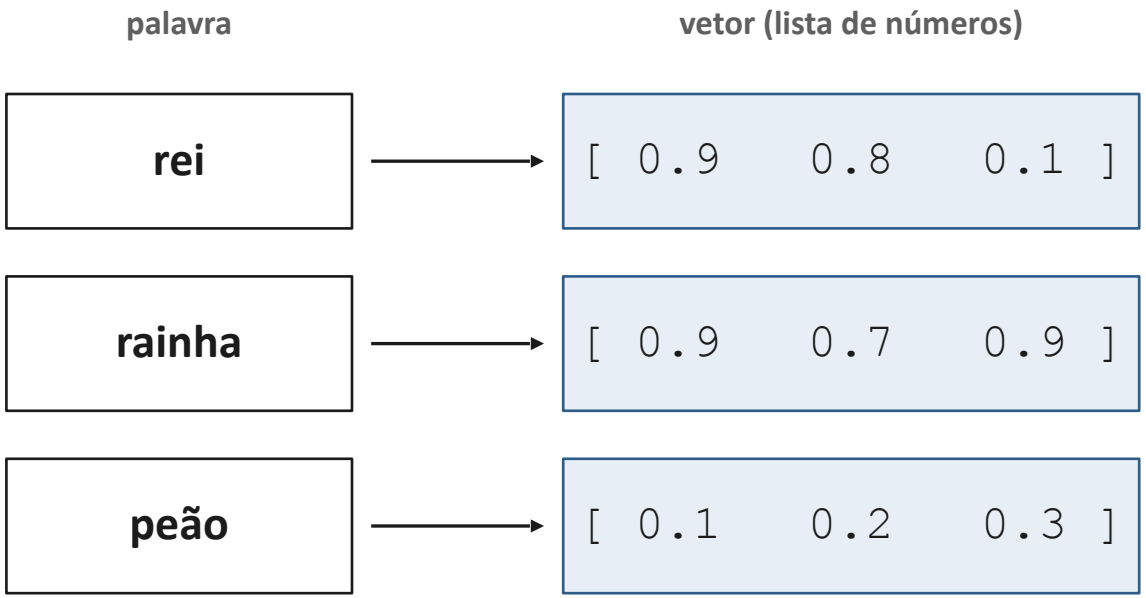


A atenção: cada palavra olha para todas as outras



Nada se perde no caminho, e todas as palavras fazem isso ao mesmo tempo.

Para o computador, palavras viram listas de números



O modelo aprende esses números

no treino. Ninguém escolhe à mão.

Palavras parecidas

ficam com números parecidos: veja rei e rainha.

Uma frase vira uma tabela

com uma linha por palavra. É com ela que a atenção trabalha.

A IDEIA

Query, key e value: como uma busca no YouTube

Query (Q)

No YouTube

o que você digita

"gol de bicicleta"

Na frase

o que a palavra procura

Key (K)

No YouTube

o título de cada vídeo

"Top 10 gols de bicicleta"

Na frase

o que a palavra oferece

Value (V)

No YouTube

o vídeo em si

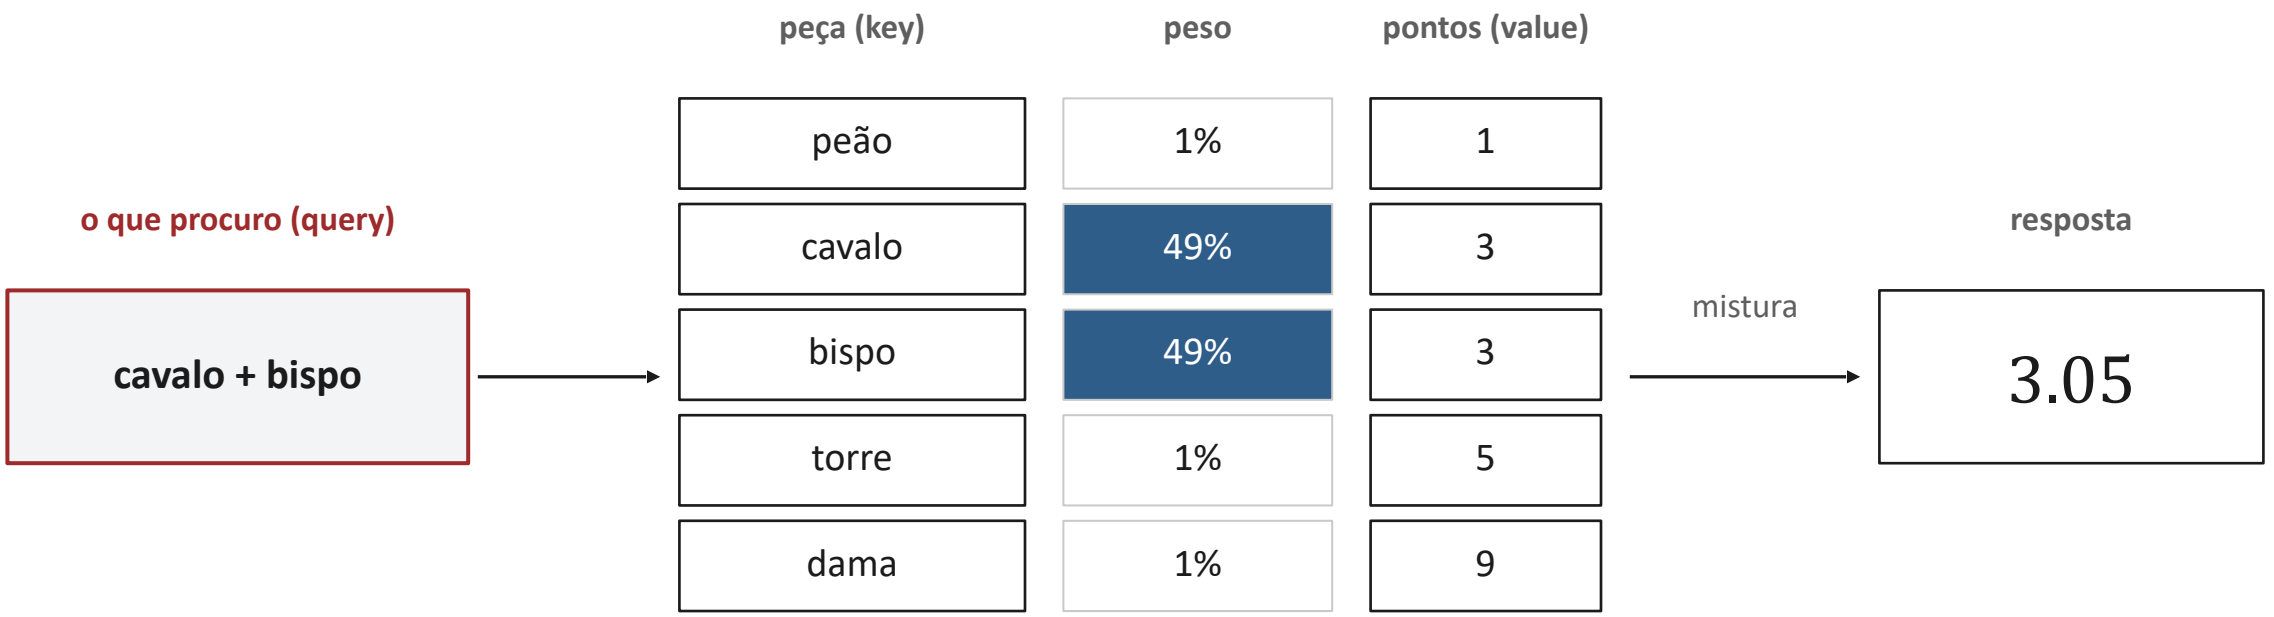
o vídeo que você assiste

Na frase

o conteúdo que a palavra entrega

A diferença: a atenção não escolhe um vídeo só. Ela mistura um pouco de cada, mais dos que combinam melhor.

Uma busca que mistura as respostas



Em vez de achar uma única entrada, a atenção mistura todas, dando mais peso às que combinam com a consulta.

Passo 1: comparar

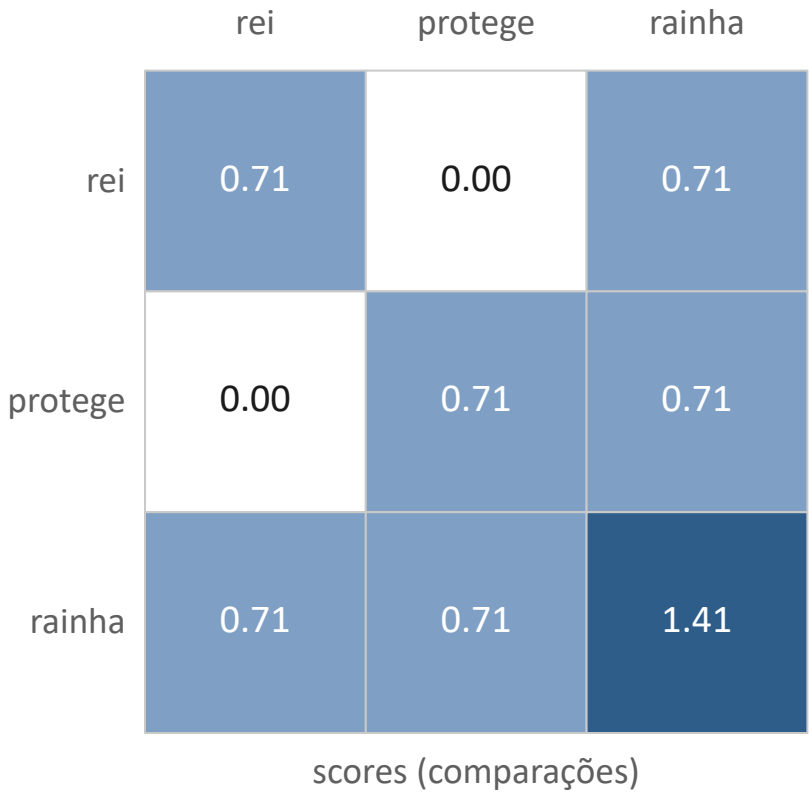
1

Cada palavra compara o que procura (query) com o que cada uma das outras oferece (key).

Número maior: combinam mais.

```
scores = Q @ K.T / np.sqrt(d_k)
```

K.T é a tabela K "deitada" (transposta), para comparar linha com linha.



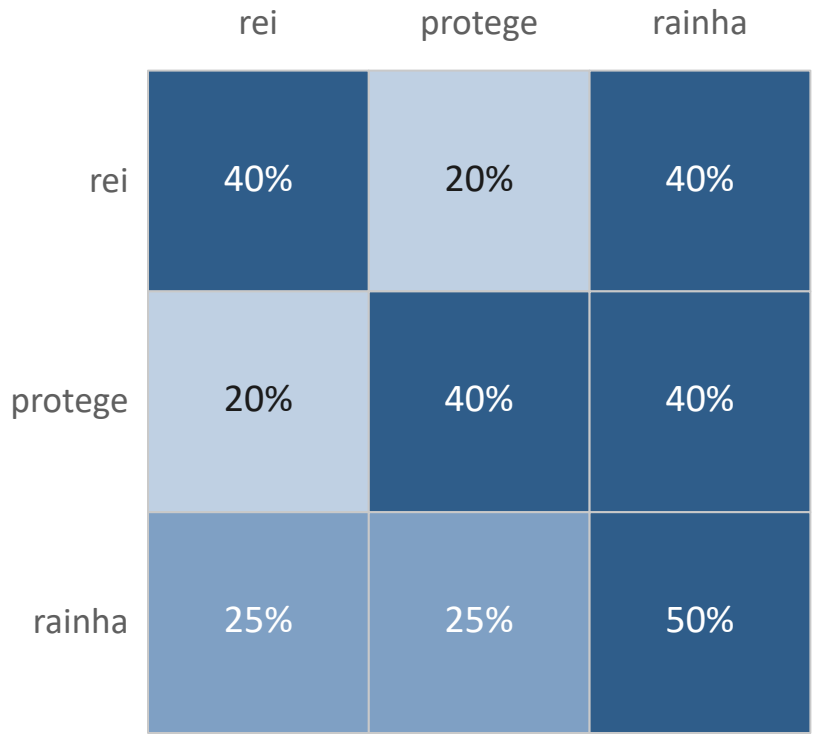
Passo 2: pesar

2

A softmax transforma cada linha em porcentagens que somam 100%.

Quem combina mais leva a maior fatia.

```
pesos = softmax(scores)
```



pesos: cada linha soma 100%

Passo 3: misturar

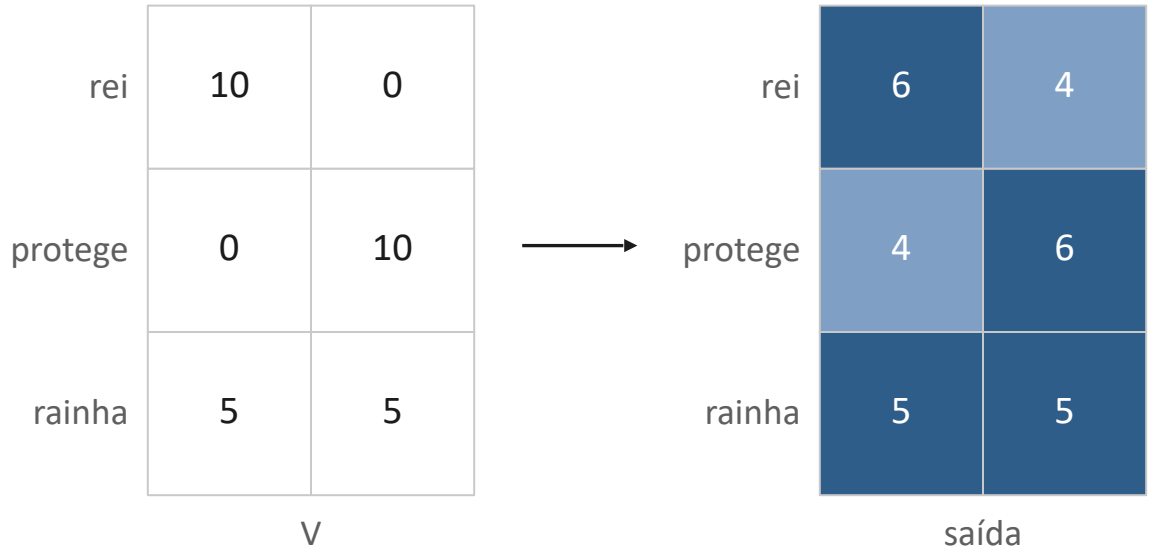
3 Cada palavra recebe uma mistura dos conteúdos (values), com essas porcentagens.

```
saida = pesos @ V
```

rei recebe:

40% de rei + 20% de protege + 40% de rainha

= [6, 4]



Os três passos numa linha: a fórmula do artigo

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right)V$$

1 Comparar

`Q @ K.T`

2 Pesar

`softmax`

3 Misturar

`@ V`

Esta linha é o coração do ChatGPT. O resto do Transformer é organização em volta dela.

Ninguém olha para o futuro

	o	rei	protege	a	rainha
o	100%	0	0	0	0
rei	14%	86%	0	0	0
protege	24%	60%	16%	0	0
a	13%	22%	29%	36%	0
rainha	8%	44%	24%	11%	13%

pesos de atenção com a máscara

Cada palavra só olha para ela mesma e para as anteriores. Acima da diagonal, o peso é zero.

Por quê? Na hora de escrever uma palavra, as seguintes ainda não existem.

```
np.tril(np.ones((T, T)))
```

tril = triângulo de baixo

PRÁTICA

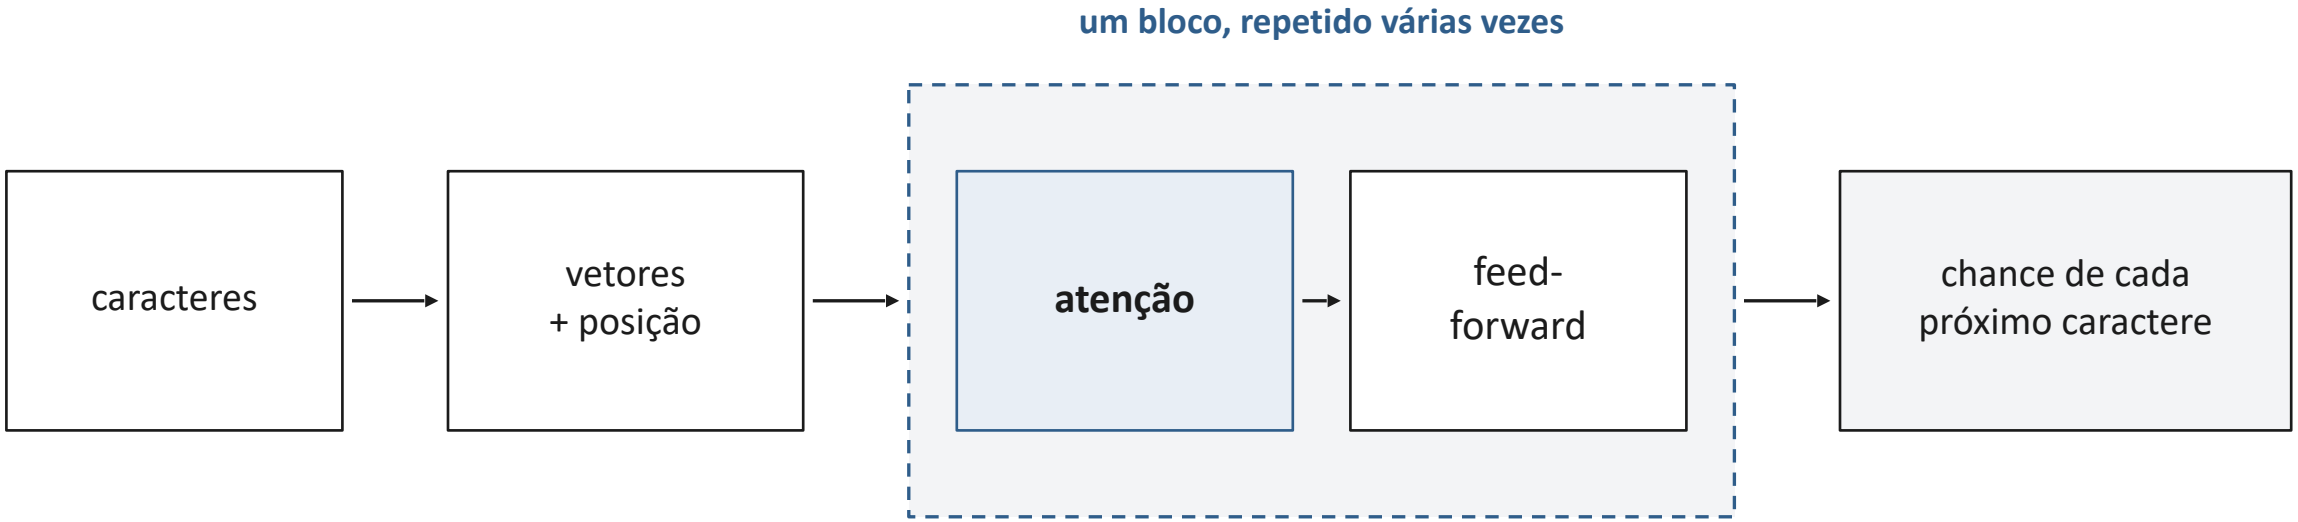
Parte 1 no notebook: a atenção

Seção 1.1	o exemplo das três palavras
Exercício 1	os três passos: comparar, pesar, misturar
Experimente	o dicionário de peças de xadrez
Exercício 2	a máscara causal

```
scores = Q @ ___   # troque por K.T
pesos = ___(scores)   # troque por softmax
saida = pesos @ ___   # troque por V
return np.tril(___)
# troque por np.ones((T, T))
```

Troque cada ___ pela resposta do comentário e aperte Shift + Enter. A célula diz se está correto.

O Transformer em uma imagem



Atenção

as palavras trocam informação entre si. É o que vocês acabaram de fazer.

Feed-forward

cada palavra "pensa sozinha" sobre o que recebeu.

Soma, não substitui

cada etapa acrescenta anotações ao que já existia, como escrever na margem em vez de apagar.

PRÁTICA

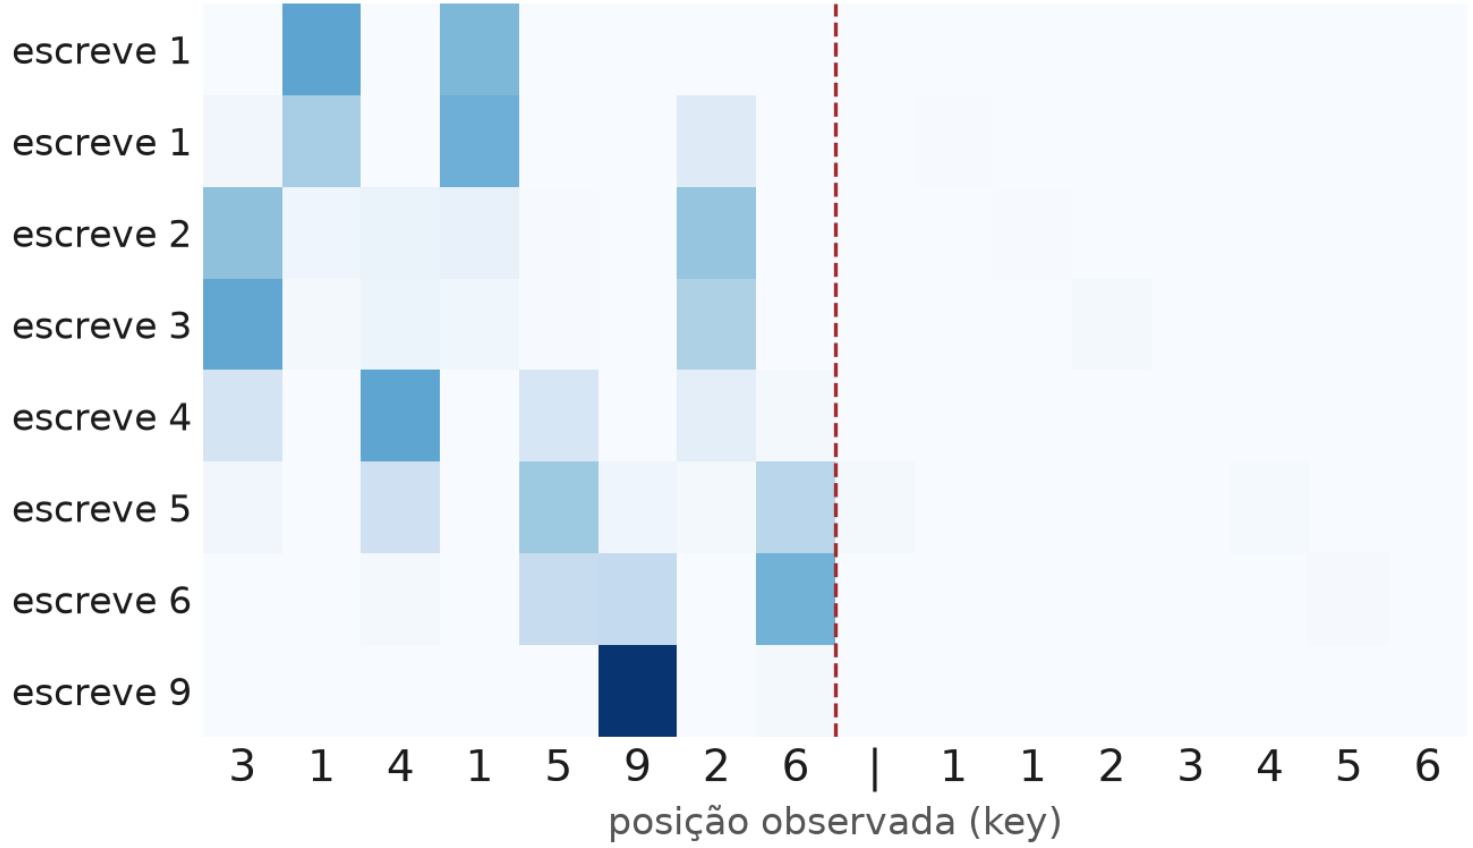
Parte 2 no notebook: o Transformer

Executar	as peças prontas do Transformer
Exercício 3	o bloco: somar em vez de substituir
Experimente	treinar o modelo de ordenação
Experimente	ver para onde ele olhou

```
# troque os dois ___ por x
x = ___ + self.attn(self.ln1(x))
x = ___ + self.ffn(self.ln2(x))
```

Antes do intervalo: execute as seções 3.1 e 3.2. O modelo de xadrez treina enquanto vocês descansam.

O que o modelo de ordenação aprendeu



`Entrada: 3 1 4 1 5 9 2 6`

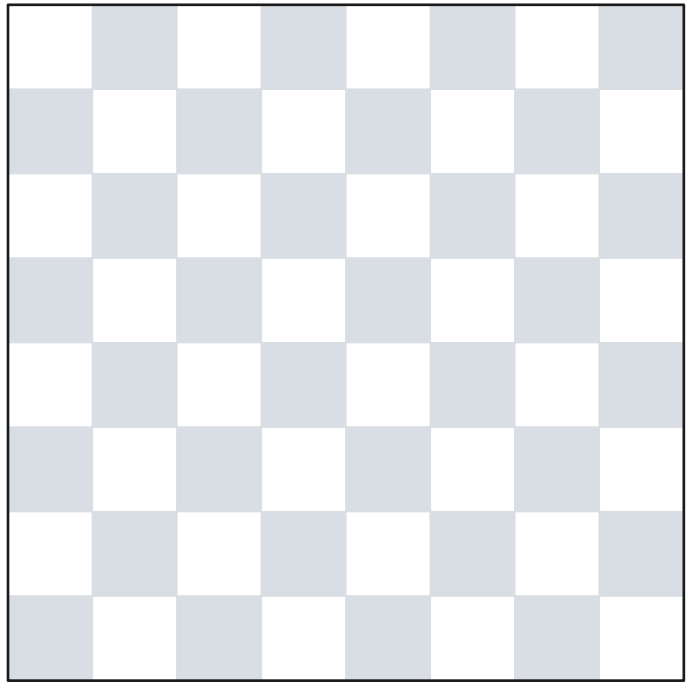
Em cada passo, o modelo olha para o número da entrada que vai escrever em seguida.

Ninguém programou essa regra: ela surgiu do treino.

Intervalo

Antes de sair, execute as seções 3.1 e 3.2.

O modelo de xadrez treina enquanto isso.



Xadrez é só mais um texto

```
;1.e4 e5 2.Nf3 Nc6 3.Bb5 a6
 4.Ba4 Nf6 5.O-O Be7 6.Re1 b5 ...
```

Escrito	Significa
e4	um peão vai para e4
Nf3	o cavalo (N) vai para f3
Bxe5	o bispo (B) captura em e5
#	xeque-mate

60 mil
partidas reais

33
caracteres diferentes

0
tabuleiros vistos pelo modelo

Se o modelo joga lances válidos sem nunca ter visto um tabuleiro, de onde vem essa noção de onde estão as peças?

PRÁTICA

Parte 3 no notebook: xadrez

seção 3.3	gerar partidas e ver onde o modelo erra
seção 3.3	mexer no controle de temperatura
seção 3.4	seu modelo contra o modelo de referência
seção 3.5	**jogar uma partida contra o modelo**

Não precisa saber xadrez: clique numa peça e os pontos mostram para onde ela pode ir.

ENCERRAMENTO

Por que a atenção mudou tudo

1 Rápido

Todas as palavras fazem a conta ao mesmo tempo. Encaixa perfeitamente nas GPUs.

2 Escala

Rápido de treinar, deu para fazer modelos enormes. E quanto maior, melhor ele fica.

3 Serve para tudo

Texto, código, imagens, som, proteínas. Tudo que vira uma sequência. Hoje, xadrez.

A arquitetura dos grandes modelos é a mesma que vocês montaram hoje. A diferença é o tamanho.

ENCERRAMENTO

Daqui até o ChatGPT

	Hoje	ChatGPT, Claude, Gemini
Lê	caracteres	pedaços de palavras
Tamanho	1 a 5 milhões de parâmetros	bilhões de parâmetros
Treino	minutos, 1 GPU	meses, milhares de GPUs
Depois	nada	ajuste para seguir instruções

A arquitetura é a que vocês escreveram hoje.

Para continuar: o vídeo "Let's build GPT", de Andrej Karpathy, e a série sobre Transformers do 3Blue1Brown.

`github.com/giovannibragasv/transformer-do-zero`

Obrigado.

